

# Le format **Parquet** pour la diffusion de données

## Un choix technique au service des utilisateurs

Cédric Bobinec

Insee, Pôle Didoc

Lino Galiana 

Insee, Direction des statistiques démographiques et sociales

26 novembre 2025

**Insee**   
Mesurer pour comprendre

# Contexte

- **Fichiers détail anonymisés** diffusés sur [insee.fr](https://insee.fr):
  - une ligne par observation (un logement, un individu, etc.)
  - Des produits phares: [Sirene](#), [Recensement de la population](#), [Base Tous salariés](#), [fichier des prénoms](#), [décès](#), etc.
- Destinés à des **utilisateurs avancés**:
  - Construire d'autres croisements ou regroupements que ceux proposés sur [insee.fr](https://insee.fr)
  - Des précautions d'emploi à respecter (pondérations)

# Avant **Parquet**: le recensement de la population (RP)

- Jusqu'à 100 variables et 25 millions de lignes
- Diffusion en **CSV zippés** ou **DBase** (format propriétaire)

## Exemple: Recensement de la Population

- **Fichier détail :**
  - **CSV**: > 4Go
  - **Parquet**: < 500Mo

# Enjeux

- **Plusieurs approches** pour diffuser des données:
  - **Fichier** vs **API**
- Le **choix d'un mode de diffusion** répond à un **arbitrage** entre plusieurs critères :
  - **Public cible**
  - **Finalité** (traitement, analyse, diffusion)
  - **Volumétrie**
  - **Interopérabilité**

# Limites des formats usuels

- Les **formats usuels** (CSV, JSON, XML) sont utiles pour :
  - Le traitement de **faibles volumes** de données
  - La **diffusion** de données simples
- **Limités** pour le traitement de **données volumineuses** ou **complexes**
  - **Non-compressés** : fichiers lourds
  - **Orientés ligne** : peu adaptés aux traitements analytiques
  - **Pas de métadonnées** : problèmes à la lecture

# Parquet: quel avantage ?

- Un format **interopérable** :
  - Très bien intégré aux outils des utilisateurs experts (,  ou  grâce à **Arrow** et **DuckDB**)
- Un format **optimisé** :
  - Lecture et traitement du fichier accélérés
- Un format **fiable** :
  - Données conformes à l'intention du producteur...

# Quel gain de confort pour les utilisateurs ?

| Configuration                                                                               |              |                            | Taille sur disque<br>(MiB ou GiB) |                                                                                       | Vitesse à l'import<br>(secondes) |                                                                                       |
|---------------------------------------------------------------------------------------------|--------------|----------------------------|-----------------------------------|---------------------------------------------------------------------------------------|----------------------------------|---------------------------------------------------------------------------------------|
| Format du fichier                                                                           | Partitionné? | Colonnes                   |                                   |                                                                                       |                                  |                                                                                       |
| Ensemble des données (19 735 576 observations)                                              |              |                            |                                   |                                                                                       |                                  |                                                                                       |
|  CSV       |              | Toutes (88 colonnes)       | 4.37G                             |    | 245.59                           |    |
|  Parquet   |              | Toutes (88 colonnes)       | 507.88M                           |    | 1.44                             |                                                                                       |
|  Parquet   |              | Sous-ensemble (9 colonnes) | 507.88M                           |    | 0.66                             |                                                                                       |
| Seulement le Centre Val de Loire (683 144 observations)                                     |              |                            |                                   |                                                                                       |                                  |                                                                                       |
|  CSV       |              | Toutes (88 colonnes)       | 154.32M                           |    | 12.71                            |    |
|  Parquet   | ✗            | Toutes (88 colonnes)       | 17.23M                            |                                                                                       | 0.10                             |                                                                                       |
|  Parquet   | ✓            | Toutes (88 colonnes)       | 507.88M <sup>†</sup>              |    | 1.76                             |                                                                                       |
|  CSV     |              | Sous-ensemble (9 colonnes) | 154.32M                           |  | 11.23                            |  |
|  Parquet | ✗            | Sous-ensemble (9 colonnes) | 17.23M                            |                                                                                       | 0.11                             |                                                                                       |
|  Parquet | ✓            | Sous-ensemble (9 colonnes) | 507.88M <sup>†</sup>              |  | 0.52                             |                                                                                       |

<sup>†</sup> Poids de l'ensemble des données, y compris régions différentes

Pour en savoir plus, formation de l'Insee aux bonnes pratiques  et 



# Un guide pour accompagner la diffusion

- Accompagner les utilisateurs avancés ;
- Donner envie à de nouveaux utilisateurs d'explorer ;
- Illustrer la richesse des données avec des exemples ;
- Créer un guide modifiable de manière contributive  ;
- Faire comprendre que ce choix technique innovant est au service du confort des utilisateurs.



# Des exemples s'appuyant sur les outils des utilisateurs

Classer les départements en fonction du nombre de centenaires recensés

| individus_recenses | DEPT |
|--------------------|------|
| 1 334              | 75   |
| 1 175              | 13   |
| 963                | 69   |
| 952                | 06   |

Python 

R 

R (dbplyr) 

Observable via Quarto 

```
1 duckdb.sql(  
2     """  
3     SELECT  
4         SUM(IPONDI) AS individus_recenses,  
5         DEPT  
6     FROM table_individu  
7     WHERE AGED >= 100  
8     GROUP BY DEPT  
9     ORDER BY individus_recenses DESC  
10    """  
11 )
```


# Parquet fin 2025

- Nombreux jeux de données **volumineux** diffusés en **Parquet**:
  - Insee: **Sirene**, **REU**, **RP**, **BPE**, etc.
  - Format bientôt dans le **catalogue de données (Melodi)**
  - SSM: **bases statistiques de la délinquance**
  - **data.gouv**: beaucoup de conversions en **Parquet**
- Quelques **bonnes pratiques** à mettre en oeuvre:
  - Optimiser les types des variables, trier les observations...
  - Mauviere (**2024**) donne de nombreux conseils utiles.

# Conclusion: quelles perspectives pour la diffusion de données ?

- Un complément **aux API de données**
  - Approche simple et efficace pour la récupération de données brutes
- Permet des **alternatives à Shiny ou Streamlit** pour les portails de *dataviz*
  - Des *dataviz* complexes sur des serveurs statiques avec **DuckDB** 🦆 dans le navigateur

Grasse ▼



| date       | valeur_fonciere |
|------------|-----------------|
| 2022-01-07 | 933,050         |
| 2022-01-07 | 72,500          |
| 2022-01-06 | 292,000         |
| 2022-01-14 | 75,000          |
| 2022-01-13 | 255,800         |
| 2022-01-17 | 103,000         |
| 2022-01-18 | 133,000         |

Un exemple de *dataviz* construite sur des fichiers **Parquet** sans serveur. Voir la version interactive [ici](#)

# Après **Parquet**: le recensement de la population (RP)

## Retours utilisateurs après la première diffusion du RP en **Parquet** (fin 2023)



**Romain Ferraton** • 2e

9 h (modifié)

(I'm Hiring !) CEO Architecture & Performance | Databases | Dataviz | Data I...

Super, l'insee se modernise !

C'est vrai que les CSV c'est vraiment trop gros, trop lent...

DuckDB + parquet : j'adore.



**Éric Mauvière** 🇫🇷

@ericMauviere

Le recensement en **#parquet**, génial !

Et toujours aussi bluffant de pouvoir tabuler un fichier en ligne de 500 Mo en moins de 2 secondes.

Les fichiers sur data.gouv : [data.gouv.fr/fr/datasets/re...](https://data.gouv.fr/fr/datasets/re...) et [data.gouv.fr/fr/datasets/re...](https://data.gouv.fr/fr/datasets/re...)



**Ali Hmaou** • 1er

2 mois ...

Adjoint au chef de département DATA chez Île-de-France Mobilités

Super boulot ! Et merci pour le post de blog sur l'utilisation de duckdb x parquet.

J'étais d'abord dubitatif parce que l'approche me semblait similaire à ce qu'on peut faire avec des sgbd classiques via des tables externes oracle ou "foreign" tables pg. J'ai finalement testé grâce au post de blog et approuvé à tous les niveaux : intégration ultra simple, perfs, conformité du sql au standard, et même requêtes analytiques fenêtrées 🙌

Les perfs ont même un petit qqch de magique 🤖, je vais aller lire l'article du courrier des statistiques pour comprendre.



**Samuel Osenat** • 2e

2 mois ...

Consultant Data Analyst

Temps de chargement d'une table RP exploitation principale France hexagonale en format SAS sur R : plus de 45 minutes.  
Temps de chargement de la même table au format parquet : même pas 1 minute  
That's it, that's the tweet

# Références

Mauviere, Eric. 2024. « Comment bien préparer son Parquet ». 16 mai 2024.  
<https://www.icem7.fr/outils/comment-bien-preparer-son-parquet/>.